

0 3 . 데이터 시각화

Iris 꽃 데이터 분석 및 시각화

Google Colab에서 데이터를 불러와 데이터 설명 → 분석 과정 → 시각화 결과 → 해석 순서로 정리하였다.

학생: 권순찬

1 . 데이터 설명

scikit-learn 에 포함된 Iris 데이터셋을 사용하였다. 붓꽃 1 5 0 개 표본에 대해 꽃받침(sepal)과
의 길이·너비가 기록되어 있고, 품종은 setosa, versicolor, virginica의 3 종이다.

```
In [1]: import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn.datasets import load_iris

iris = load_iris(as_frame=True)
df = iris.frame.copy()
df['species'] = df['target'].map(dict(enumerate(iris.target_names)))
df = df.drop(columns='target')

print('데이터 크기:', df.shape)
print('품종:', list(iris.target_names))
df.head()
```

데이터 크기: (150, 5)

품종: [np.str_('setosa'), np.str_('versicolor'), np.str_('virginica')]

```
Out[1]:
```

	sepal length (cm)	sepal width (cm)	petal length (cm)	petal width (cm)	species
0	5.1	3.5	1.4	0.2	setosa
1	4.9	3.0	1.4	0.2	setosa
2	4.7	3.2	1.3	0.2	setosa
3	4.6	3.1	1.5	0.2	setosa
4	5.0	3.6	1.4	0.2	setosa

2 . 분석 과정 - 결측치와 기초 통계 확인

먼저 데이터 크기, 결측치, 변수별 평균·표준편차·최솟값·최댓값을 확인한다.

```
In [2]: print('결측치 개수')
print(df.isna().sum())
print('\n기초 통계')
display(df.describe().round(2))
```

결측치 개수

```
sepal length (cm)    0
sepal width (cm)     0
petal length (cm)    0
petal width (cm)     0
species              0
dtype: int64
```

기초 통계

	sepal length (cm)			sepal width (cm)			petal length (cm)			petal width (cm)		
count	1	5	0.0	0	0	0	1	5	0.0	0	0	0
mean	5.84			3.06			3.76			1.20		
std	0.83			0.44			1.77			0.76		
min	4.30			2.00			1.00			0.10		
25%	5.10			2.80			1.60			0.30		
50%	5.80			3.00			4.35			1.30		
75%	6.40			3.30			5.10			1.80		
max	7.90			4.40			6.90			2.50		

해석


결측치가 없어 별도의 결측치 처리가 필요하지 않다. 네 측정 변수는 모두 연속형 수치이므로 품종별 분포의 관계를 그래프로 비교할 수 있다.

3. 시각화 1 - 품종별 표본 수

세 품종의 데이터 수가 균형 있게 구성되어 있는지 확인한다.

```
In [3]: counts = df['species'].value_counts().reindex(iris.target_names)
plt.figure(figsize=(7, 4))
plt.bar(counts.index, counts.values)
plt.title('Number of Samples by Species')
plt.xlabel('Species')
plt.ylabel('Count')
plt.ylim(0, 60)
for i, v in enumerate(counts.values):
    plt.text(i, v + 1, str(v), ha='center')
```

```
plt.tight_layout()
plt.show()
```




해석

각 품종이 50 개씩 포함되어 있어 품종별 표본 수가 동일하다. 특정 품종이 지나치게 많아 비교가 왜곡적이다.

4. 시각화 2 - 꽃받침 길이와 꽃잎 길이의 관계

품종별로 두 길이 변수의 관계가 어떻게 달라지는지 산점도로 확인한다.

```
In [4]: plt.figure(figsize=(7, 5))
for species in iris.target_names:
    part = df[df['species'] == species]
    plt.scatter(part['sepal length (cm)'], part['petal length (cm)'], label=species,
plt.title('Sepal Length vs Petal Length')
plt.xlabel('Sepal length (cm)')
plt.ylabel('Petal length (cm)')
plt.legend()
plt.tight_layout()
plt.show()
```




해석

setosa는 꽃잎 길이가 짧은 영역에 뚜렷하게 모여서 다른 두 품종과 쉽게 구분된다. versicolor와 virginica는 겹치지만, 전반적으로 virginica의 꽃잎 길이가 더 긴 편이다.

5. 시각화 3 - 품종별 꽃잎 길이 분포

상자그림으로 품종별 꽃잎 길이의 중앙값과 분포 범위를 비교한다.

```
In [5]: groups = [df.loc[df['species'] == s, 'petal length (cm)'] for s in iris.target_names]
plt.figure(figsize=(7, 5))
plt.boxplot(groups, tick_labels=iris.target_names)
plt.title('Petal Length Distribution by Species')
plt.xlabel('Species')
plt.ylabel('Petal length (cm)')
plt.tight_layout()
plt.show()
```



해석

꽃잎 길이의 중앙값이 setosa < versicolor < virginica 순으로 증가한다. 특히 setosa의 분포는 다른 품종과 거리가 멀어 이 품종을 구분하는 데 유용한 변수임을 확인할 수 있다.


6. 시각화 4 - 수치 변수 간 상관관계

상관계수를 계산하고 행렬 형태로 시각화하여 함께 증가하거나 감소하는 변수 쌍을 확인한다.

```
In [6]: numeric = df.drop(columns='species')
corr = numeric.corr()

plt.figure(figsize=(7, 6))
im = plt.imshow(corr, vmin=-1, vmax=1, cmap='coolwarm')
plt.colorbar(im, fraction=0.046, pad=0.04, label='Correlation')
plt.xticks(range(len(corr.columns)), ['Sepal L', 'Sepal W', 'Petal L', 'Petal W'], rotation=45)
plt.yticks(range(len(corr.columns)), ['Sepal L', 'Sepal W', 'Petal L', 'Petal W'])
for i in range(len(corr)):
    for j in range(len(corr)):
        plt.text(j, i, f'{corr.iloc[i, j]:.2f}', ha='center', va='center')
plt.title('Correlation Matrix')
plt.tight_layout()
plt.show()
```

```
print(corr.round(2))
```



	sepal length (cm)	...	petal width (cm)
sepal length (cm)	1.00	...	0.82
sepal width (cm)	-0.12	...	-0.37
petal length (cm)	0.87	...	0.96
petal width (cm)	0.82	...	1.00

[4 rows x 4 columns]

해석

꽃잎 길이와 꽃잎 너비는 매우 강한 양의 상관관계를 보인다. 꽃받침 길이도 꽃잎 길이·너비와 양의 관계가
침 너비는 다른 변수와의 관계가 상대적으로 약하다.

7. 결론

Iris 데이터는 세 품종이 동일한 수로 구성되어 있으며 결측치가 없다. 시각화를 통해 **꽃잎 길이와 꽃잎 너비**를 가장 분명하게 보여주는 변수임을 확인했다. 단순한 표만 볼 때보다 산점도, 상자그림, 상관행렬을 함께 변수의 분포와 관계를 더 쉽게 파악할 수 있었다.