

데이터 시각화 - Colab 분석

- 과목: 프로그래밍 수행평가
- 작성: 3 0 8 0 1 권순찬
- 작성 환경: Google Colab / Python

데이터 설명

scikit-learn 에 포함된 Iris 데이터셋을 사용합니다. 붓꽃 3 개 품종 1 5 0 개 표본에 대해 꽃받개 길이·너비 4 개 변수가 있습니다.

분석 과정에서는 데이터를 표 형태로 확인하고, 품종별 평균 비교 → 꽃잎 길이·너비 산점도 → 변수 간 상관관계 시각화한 뒤 결과를 해석합니다.

In [1]:

```
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.datasets import load_iris

iris = load_iris(as_frame=True)
df = iris.frame.copy()
df['species'] = df['target'].map(dict(enumerate(iris.target_names)))
df = df.drop(columns=['target'])
print(df.head())
print('shape:', df.shape)
print(df['species'].value_counts())
```

	sepal length (cm)	sepal width (cm)	...	petal width (cm)	species
0	5.1	3.5	...	0.2	setosa
1	4.9	3.0	...	0.2	setosa
2	4.7	3.2	...	0.2	setosa
3	4.6	3.1	...	0.2	setosa
4	5.0	3.6	...	0.2	setosa

```
[5 rows x 5 columns]
shape: (150, 5)
species
setosa      50
versicolor  50
virginica   50
Name: count, dtype: int64
```

분석 1. 품종별 평균


In [2]:

```
means = df.groupby('species').mean(numeric_only=True)
print(means)
means.plot(kind='bar', figsize=(10,5))
```

```
plt.title('Mean measurements by species')
plt.ylabel('cm')
plt.xticks(rotation=0)
plt.tight_layout()
plt.show()
```

	sepal length (cm)	...	petal width (cm)
species		...	
setosa	5.006	...	0.246
versicolor	5.936	...	1.326
virginica	6.588	...	2.026

[3 rows x 4 columns]



해석


- setosa는 꽃잎 길이와 너비가 다른 두 품종보다 뚜렷하게 작습니다.
- virginica는 네 변수의 평균이 전반적으로 가장 큼니다.
- 특히 꽃잎 관련 변수는 품종 간 차이가 크게 나타나 분류에 유용해 보입니다.

분석 2. 꽃잎 길이와 너비 산점도

In [3]:

```
fig, ax = plt.subplots(figsize=(7,5))
for species, g in df.groupby('species'):
    ax.scatter(g['petal length (cm)'], g['petal width (cm)'], label=species,
               alpha=0.7)
ax.set_xlabel('Petal length (cm)')
ax.set_ylabel('Petal width (cm)')
ax.set_title('Petal length vs width')
ax.legend()
```

```
plt.tight_layout()
plt.show()
```



해석

꽃잎 길이가 길수록 꽃잎 너비도 커지는 경향이 뚜렷합니다. setosa는 별도의 작은 군집을 형성하고, versicolor도 상당 부분 구분됩니다.

분석 3. 변수 간 상관계수와 히트맵


In [4]:

```
corr = df.select_dtypes('number').corr()
print(corr.round(3))
fig, ax = plt.subplots(figsize=(6,5))
im = ax.imshow(corr, vmin=-1, vmax=1)
ax.set_xticks(range(len(corr.columns)), corr.columns, rotation=45, ha='right')
ax.set_yticks(range(len(corr.columns)), corr.columns)
for i in range(len(corr.columns)):
    for j in range(len(corr.columns)):
        ax.text(j, i, f'{corr.iloc[i,j]:.2f}', ha='center', va='center')
fig.colorbar(im, ax=ax)
ax.set_title('Correlation matrix')
```

```
plt.tight_layout()
plt.show()
```

	sepal length (cm)	...	petal width (cm)
sepal length (cm)	1.000	...	0.818
sepal width (cm)	-0.118	...	-0.366
petal length (cm)	0.872	...	0.963
petal width (cm)	0.818	...	1.000

[4 rows x 4 columns]



해석

꽃잎 길이와 꽃잎 너비 사이의 상관관계가 매우 높습니다. 반면 꽃받침 너비는 다른 변수들과의 관계가 상대적으로

결론

Iris 데이터에서는 **꽃잎 길이와 너비**가 품종 차이를 가장 뚜렷하게 보여 주는 변수입니다. 산점도에서도 세 품종 잘 분리되며, 상관분석에서도 두 변수는 강한 양의 관계를 보였습니다.